# 目录


**第一章 导言** **1**

**第二章 线性度量学习** **3**

第 1 节 问题目标 . . . . . 3

第 2 节 Mahalanobis 距离 . . . . . 4

第 3 节 主成分分析与线性判别分析 . . . . . 6

第 4 节 监督学习的优化建模 . . . . . 7

4.1 扩大边缘最近邻 (LMNN) 模型 . . . . . 8

**第三章 非线性度量学习** **10**

第 1 节 问题目标 . . . . . 10

第 2 节 核技巧 . . . . . 11

2.1 核化支持向量机 (SVM) . . . . . 11

2.2 正则化项的谱理论 . . . . . 12

2.3 度量学习的表示定理 . . . . . 13

2.4 基于核化主成分分析 (KernelPCA) 的核方法 . . . . . 14

第 3 节 多核学习 . . . . . 14

3.1 多核学习在 LMNN 中的应用 . . . . . 14

第 4 节 算法实验 . . . . . 15

**第四章 延伸讨论** **17**

第 1 节 核函数法之外的非线性度量学习 . . . . . 17

1.1 非 Mahalanobis 方法 . . . . . 17

1.2 概率方法 . . . . . 18

1.3 卷积神经网络 (CNN) 方法 . . . . . 18

1.4 流形学习 . . . . . 18

**第五章 小结** **19**

# 非线性度量学习及应用

傅长青
学号：13300180003
专业：信息与计算科学

**摘要**

**动机：** 度量学习的目标是给定数据, 求空间中的度量结构使得基于度量的算法效果最佳. 假设度量空间具有凸性和线性性, 度量由正定矩阵给出, 由对称正定 Mahalanobis 决定. 假设非线性, 将条件减弱为局部凸时, 可以引入核方法 (Kernel Method) 进行处理, 或者用局部度量的方法等. 鉴于特殊核函数的表示能力不足, 可以推广为多核的结合. 特别地, 核函数法仍然是基于线性 Mahalanobis 距离, 本文最后一章讨论了非线性度量的直接方法.

**方法：** 本文通过归纳不同类型的度量学习算法, 提供了度量学习的框架和背后的出发点. 其中包括*正则化项* (尤其是谱理论), *损失函数* (尤其是经典论文中的应用) 和*核函数* (尤其是多核学习). 着重测试, 分析了实际使用中各种经典的正则化模型, 多核学习, 神经网络法, 和一些数据降维 (流形学习) 等等的优势与劣势. 提供了可以运行在经典标准数据集 (UCI, MNIST 手写数据等) 上的 matlab 算法包, 开放方便研究使用. 是第一篇使用中文整理的度量学习程序手册.

**使用：** 本论文的相关代码在http://changqingfu.com/可以获得.

**关键字**: 机器学习, 相似度学习, 度量学习, 核方法, 流形学习.

# 第一章　导言

机器学习的一个分支是*相似性学习*, 给定一些数据的相似性矩阵 (即图论中的带权邻接矩阵), 求任意数据的*相似度*, 或者称为广义的*度量*. 举一个例子, 地球上两地之间的度量通常定义为测地线的长度. 这是球面几何空间结构意义下的度量. 如果我们考虑地形, 同样定义测地线距离, 那么这个度量会复杂得多. 但是日常生活中我们可能并不关心这样的度量, 例如安排出行时, 如果重新定义 "度量" 为时间距离 $\mathscr{D}$: 步行或者坐给定的交通工具, 从其中一点到达另外一点的最短时间

$$\mathscr{D}(a,b)=\min\{T|\exists\ X_t,\mathrm{s.\,t.}\,X_0=a,X_T=b\}$$

那么由这个定义出发, 伦敦和纽约之间的距离比珠穆朗玛峰到云南的距离要近得多. 再假设为了研究物种迁移, 标记群岛中的鱼. 假设鱼群从群岛中的小岛 $a$ 游到小岛 $b$ 的现象, 描述为二维随机过程 $X_t$, 服从满足一阶自治微分方程

$$\mathrm{d}X_t=\mu(X_t)\,\mathrm{d}t+\sigma(X_t)\,\mathrm{d}B_t,$$

所需要的时间 $\mathscr{D}(a,b)$, 定义为

$$\mathscr{D}(X_t,a,b)=\mathbb{E}\left(\tau_b\left(X_t\right)|X_0\in a\right).$$

其中 $\tau_b(X_t)(\omega)=\inf\{t>0\,|X_t(\omega)\in b\}$, $B_t$ 是标准布朗运动. 这些问题中知道一系列数据 $(a_i,a_j)$ 的距离 $\mathscr{D}(a_i,a_j)$, 反过来求空间结构 (比如这里的交通工具路线图, 或者水流速场 $\mu$), 便是相似性学习.

这是一个*反问题 (inverse problem)*, 所谓反问题就是已知观测数据, 求导致这些观测数据的因素. 这个问题中, 空间隐含的局部或者整体的度量结构, 导致了数据所在空间的中每两个点显现出一个度量的值. 统计学习中, 相似性学习有不同的提法, 换句话说, 度量学习可以应用于不同的框架: 诸如分类, 回归, 排名等等. 本文仅仅以*分类 (Clustering) 问题* (例如推荐算法) 为例, 目的是使用有限的数据 (无论标记了类别与否), 求一个度量结构使得任意的数据都可以很容易的区分不同类别.

最简单相似度是欧氏空间中通常意义上的距离. 常用的分类方法包括 KNN 等基于距离的方法. 但是一旦遇到欧氏距离无法分割的情况 (比如不同特征的数量级差别非常大), 分类效率常常变得很低. 在更一般的问题中, 线性的度量根本无法区分不同的类别. 归纳起来, 困难主要体现在:(1) 样本协方差矩阵条件数太大导致单位度量矩阵 (欧氏距离) 下的模型失效.(2) 聚集于非线性边界附近的数据无法分割. 这时我们需要一个非线

性的度量, 我们将说明这个问题等价于一个非线性变换, 把数据投影到某个空间内, 将问题转化为新的空间内的线性分类问题.

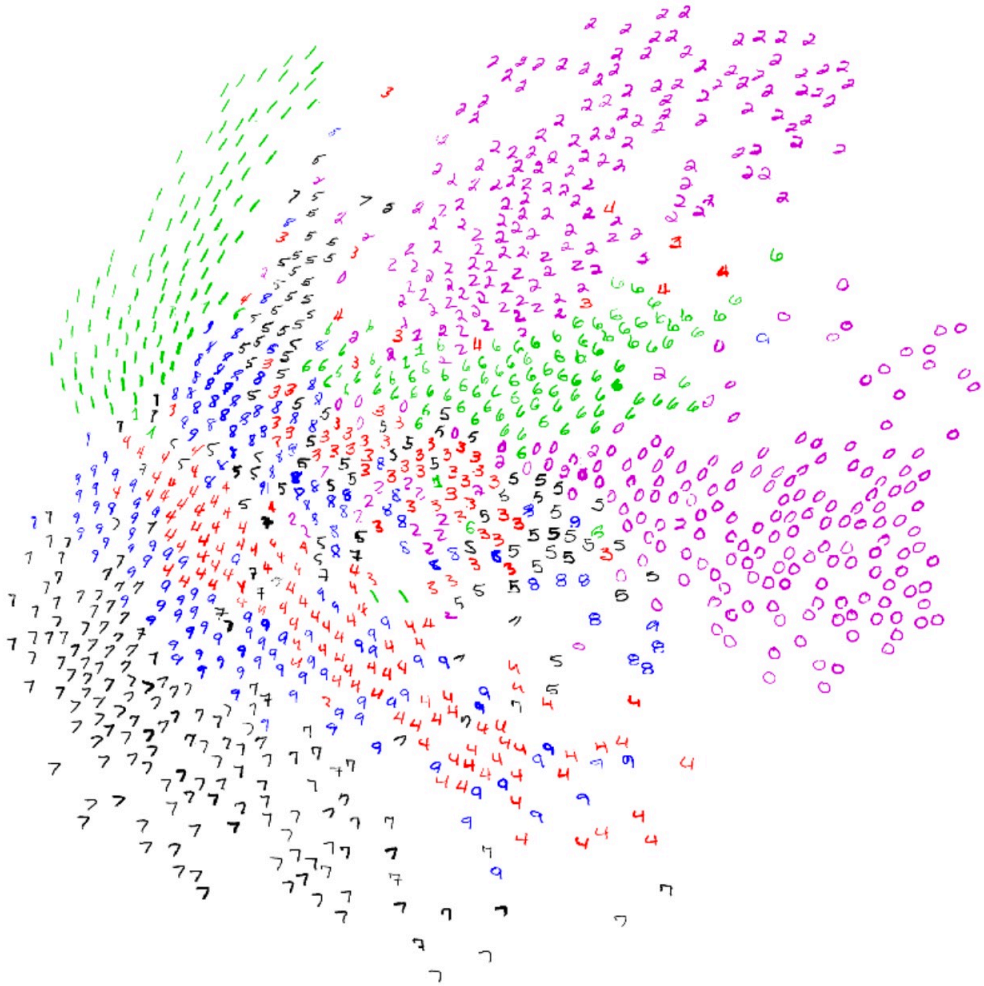

图 1.1: 手写数字图片的高维数据通过神经网络构成的非线性变换后投影到二维平面在欧氏距离下的结构, 使得分类成为可能 (实际分类时投影在 30 维空间内便足以线性分离). 图片来自 [11].

在本文中我们将回顾度量学习的各种方法, 从无监督到监督, 从线性到非线性, 从核方法到非核方法, 从抽象问题到算法模拟. 第一章包括线性度量学习的目标, 理论背景, 无监督和监督情形下的问题建模详细介绍了扩大边缘最近邻法, 第二章介绍了非线性度量学习的核技巧方法, 详细介绍了多核学习, 进行了算法模拟, 并在基准数据集上与其他算法进行比较. 第三章主要介绍其他非线性方法, 包括局部线性和非核方法的非线性度量学习.

# 第二章　线性度量学习

## 第 1 节　问题目标

为了说明度量学习的意义, 下面举两个例子.

**例 1 (无监督学习)**　对于两个不同均值, 同方差的二元高斯分布, 分别模拟 100 个点, 如图 [3.3]. 当均值距离比较远的时候, 即使不使用标记数据, 也可以用 k-means 很容易的分开两个类别. 但是如果其中一个坐标数据点聚集在一起时, 分类的效率会变得很低.

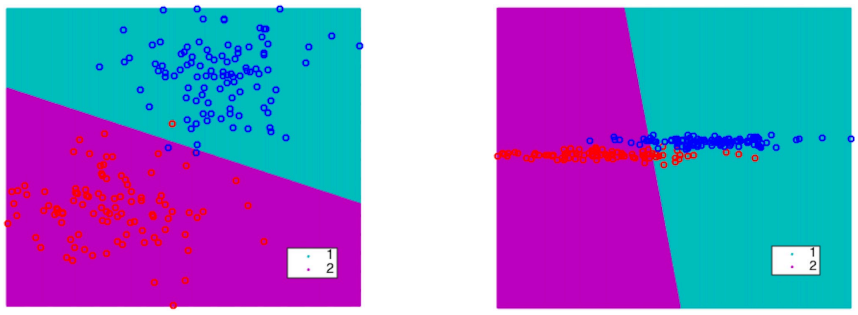


图 2.1: 两组数据的协方差矩阵分别很小或很大的 kmeans 二分类结果. 右图与左图相比, 仅仅对纵坐标做了线性变换, 却在欧氏度量下不再可以明显分割, 这是因为 kmeans 算法只关心均值, 不关心协方差矩阵, 决策边界是每两个均值的中垂面.

这在通常的分类数据中很常见. 例如某几个地区电站的日用电量数据是千瓦时, 数量级为 $10^5$, 另一个特征温度的范围是 $0 \sim 35°C$, 就会造成类似的结果.

如果应用 EM 方法 (算法1) 逐步迭代优化这个多元函数的均值和协方差矩阵, 可以解决图二的问题, 代价是计算量大幅提升. 下一节将提供更加直接的方法.EM 方法在第四章1.2节的延伸讨论中也会用到.

**算法 1** GMM-EM: 混合高斯分布的期望最大化算法

*需要: 无标记数据, 类别个数* $n$

> 用 kmeans 初始化 $\boldsymbol{\mu}_0, \boldsymbol{\sigma}_0$, 平均初始化权重,$n$ 维向量 $\boldsymbol{k}_0$

> 如果 算法未收敛, 或 $i \leq N$, 执行:

>　　E 步: 计算每一点在这一步的分布函数$\big(\theta_i = (k_{i+1}\boldsymbol{\mu}_{i+1}, \boldsymbol{\sigma}_i)\big)$下出现的概率 (Membership Probability)

>　　M 步: 最大化似然函数解得 $\boldsymbol{k}_{i+1}, \boldsymbol{\mu}_{i+1}, \boldsymbol{\sigma}_{i+1}$

>　　$i = i + 1$

> 循环

**例** 2 (**监督学习**)　再看一个实际问题的例子:UCI 机器学习数据库 [14] 中的 wine 数据, 是三种不同的酒中 13 种化学成分, 共 178 条数据. 从三种酒中分别随意挑选一条数据如下:

第 1 种:14.75,1.73,2.39,11.4,91,3.1,3.69,.43,2.81,5.4,1.25,2.73,1150

第 2 种:12.37,1.07,2.1,18.5,88,3.52,3.75,.24,1.95,4.5,1.04,2.77,660

第 3 种:12.96,3.45,2.35,18.5,106,1.39,.7,.4,.94,5.28,.68,1.75,675

其中最后两个特征 (化学物质名称分别是 OD280/OD315 和 Proline) 的数量级差别达到 $10^3$, 和上一例类似, 这会导致分类算法对数量级小的分量不敏感.

注意到这个例子中可以利用的信息还有分类标记, 进一步还可以定义损失函数, 使得分类正确率更高的相似性函数 $d$ 的损失函数值更低. 然后最小化这个损失函数, 从而得到“实证”意义下最优的相似性函数.

这启发我们寻找一个比欧氏距离更一般的距离作为相似性函数, 这就是**度量学习**.

回忆度量的定义:

**公理** 2.1. (**度量**)　$d(\cdot,\cdot)$ 的构造应该满足如下的条件: 对 $\forall x, y, z$,

(1) **正定性**　$d(x,y) \geq 0$. 最相似的点 (视为同一个点) $d$ 定义为 0

(2) **对称性**　$d(x,y) = k(y,x)$

(3) **凸性 (三角不等式)**　$d(x,y) + d(y,z) \geq d(x,z)$

先考虑**线性**的无监督度量学习, 就是 Mahalanobis 距离.

## 第 2 节　Mahalanobis 距离

$\mathbb{R}^n$ 是一个有限维实内积空间, 其上的内积对应半正定 (psd) 二次型, 或者对应半正定对称 Hermite 矩阵 $\mathbf{W}$(称为 Gram 矩阵, 其全体为一个凸锥 $\mathcal{S}_+^d$), 由内积自然诱导出范数和度量:$d_{\mathbf{W}}(x_1, x_2)^2 = (x_1 - x_2)^\top \mathbf{W}(x_1 - x_2)$. 其中 $\mathbf{W} \succeq 0$(半正定). 事实上充分性也成立:$\mathbf{W} \succeq 0$, $\mathbf{W} = \mathbf{W}^\top$, 则 $d_{\mathbf{W}}$ 是一个度量. 这样的 $\mathbf{W}$ 称为 *Mahalanobis* 矩阵

为了简便起见, 下文中的 Mahalanobis 距离一般不再求平方根:

**定义** 2.2. (Mahalanobis **距离**)　设 $\mathbf{W} \in \mathcal{S}_+^d$, 则相应的 Mahalanobis 距离的平方为

$$d_{\mathbf{W}}^2(x_1, x_2) = (x_1 - x_2)^T \mathbf{W}(x_1 - x_2)$$

$\mathbf{W}$ 可以分解为 $\mathbf{W} = \mathbf{L}^\top \mathbf{L}$, 其中 $\mathbf{L} \in \mathbb{R}^{e \times d}$, 且 $e \geq \operatorname{rank}(\mathbf{W})$. 距离 $d_{\mathbf{W}}$ 可以写作

$$d_{\mathbf{W}}^2(x_1, x_2) = (x_1 - x_2)^\top \mathbf{W}(x_1 - x_2) = (x_1 - x_2)^\top \mathbf{L}^\top \mathbf{L}(x_1 - x_2) = \|\mathbf{L}(x_1 - x_2)\|_2^2 = \|x_1' - x_2'\|_2^2$$

即可以将 $\mathbf{W}$ 诱导的距离视为 $\mathbf{L}$ 变换后新的基下的欧氏距离, 其中 $x_1' = \mathbf{L}x_1$ and $x_2' = \mathbf{L}x_2$.

**注** 2.1　事实上这是 Mercer (1909) 定理的特殊情形: 假设 $k(\cdot, \cdot)$ 是 $X$ 上的连续对称正定函数,$T_k\varphi(x) = \int_a^b k(x, s)\varphi(s)\,\mathrm{d}s$. 则 $\langle T_k\varphi, \psi\rangle = \int k(t, s)\varphi(s)\psi(t)\,\mathrm{d}s\,\mathrm{d}t$, 由对称性,$T_k$ 是一个紧自伴 (也是正规) 算子. 由紧算子的谱定理, 存在正交基 $\{e_i(t)\}_i \subseteq L^2(X)$ 使得 $k(s, t) = \sum_{j=1}^\infty \lambda_j e_j(s) e_j(t)$. 最后, 为了说明紧性, $T_k$ 在 $L^2[a, b]$ 单位球上等度连续, 由 Arzela-Ascoli 定理, 单位球的像在 $L^2[a, b]$ 中在一致范数下紧.

当 $k$ 取为 $\mathbf{W}$ 对应的二次型

$$\begin{aligned} d_{\mathbf{W}}: \quad & \mathbb{R}^d \times \mathbb{R}^d \longrightarrow \mathbb{R} \\ & (x_i, x_j) \longmapsto x_i^\top \mathbf{A} x_j, \end{aligned}$$

$\sum_i \sqrt{\lambda_i} e_i(\cdot)$ 取为线性变换 $L$, 即为这里的情形.

**注** 2.2　对于一般的非线性二元函数, 下文称为核函数的 $k$, Mercer 定理还会用到, 这里的 $k$ 若满足 Mercer 条件 (Mercer's Condition), 即连续对称正定, 则可以分解为 $k(x_i, x_j) = \langle \Phi(x_i), \Phi(x_j)\rangle$ 即将 $\Phi$ 视为谱映射

$$\begin{aligned} \Phi: \quad & \mathbb{R}^d \longrightarrow l^2(\mathbb{R}_+), \text{称为核空间} \\ & x \longmapsto (\sqrt{\lambda_i})_i \end{aligned}$$

将 x 映为特征映射的谱集 $\sigma(\varphi)$.

对于无监督学习 (没有标记的数据), 由第一节的例子启发, 我们希望变换后的数据的协方差矩阵为单位阵 (即满足 Gauss-Markov 性质), 最直接的方法是去相关性: $\mathbf{W} = \mathbf{S}^{-1}$, 或 $\mathbf{L} = \mathbf{S}^{-\frac{1}{2}}$. 其中 $\mathbf{S}$ 是协方差矩阵, 定义为 $\mathbf{S} = \mathbb{E}\Big((\mathbf{X} - \mathbb{E}\mathbf{X})(\mathbf{X} - \mathbb{E}\mathbf{X})^\top\Big)$, 但在实际问题中往往不知道数据真实的分布, 所以用样本协方差矩阵代替. 有的文献也称之为白噪化 *(whitening)*, 即将数据变成同方差, 不相关的白噪声. 如果假设给定数据已经不相关, 那么 Mahalanobis 矩阵为一个对角阵, 这个距离也叫做标准化欧氏距离.

此外还有使用向量夹角余弦作为距离函数的方法等等, 适用于数据分散在零点的各个方向的情形, 在向量化文本分类中颇为有效.

## 第 3 节　主成分分析与线性判别分析

假设希望忽略小方差的方向, 而将数据降维, 就是著名的**主成分分析** *(PCA)* 方法, 线性变换 $\mathbf{L}$ 将数据投影到非零特征值对应的特征空间内, 相应的优化问题可以写作:

$$\max_{\mathbf{L}} \operatorname{tr}(\mathbf{L}^\top \mathbf{S}\mathbf{L}) \,\mathrm{s.t.}\, \mathbf{L}\mathbf{L}^\top = \mathbf{I},$$

其中协方差矩阵 $\mathbf{S} = \frac{1}{n}\sum_{i=1}^{n}(x_i-\mu)(x_i-\mu)^\top$. 当 $\mathbf{L}$ 是长方阵时投影到低维子空间内; 当 $\mathbf{W}$ 不可逆时不降维.PCA 相当于将协方差矩阵从大到小的特征值对应的特征向量 $v_i$ 作为第 $i$ 个坐标轴, 这样一来前几个坐标轴张成的子空间包含了数据的 "主要信息"(大方差的方向). 但例1的问题并没有解决.

在监督学习的背景下, 这个方法可以推广为**线性线性判别分析** *(Linear Discriminant Analysis, LDA, Fisher 1936)* 每一个类别的数据都去相关化, 这样就解决了例1中的问题.LDA 对应的优化问题为:

$$\max_{\mathbf{L}} \operatorname{tr}\left(\frac{\mathbf{L}^\top \mathbf{S}_b \mathbf{L}}{\mathbf{L}^\top \mathbf{S}_w \mathbf{L}}\right) \,\mathrm{s.t.}\, \mathbf{L}\mathbf{L}^\top = \mathbf{I}.$$

其中不同组际协方差 $\mathbf{S}_b = \frac{1}{m}\sum_{i=1}^{m}\boldsymbol{\mu}\boldsymbol{\mu}^\top$, 同组间协方差 $\mathbf{S}_w = \frac{1}{n}\sum_{i=1}^{p}\sum_{i\in\Omega_{\mathcal{S}}}(x_i-\mu_{\mathcal{S}})(x_i-\mu_{\mathcal{S}})^\top$. 相似等价类 $\Omega_{\mathcal{S}} = \{[i] | i \sim j \text{ iff } y_i = y_j\}$

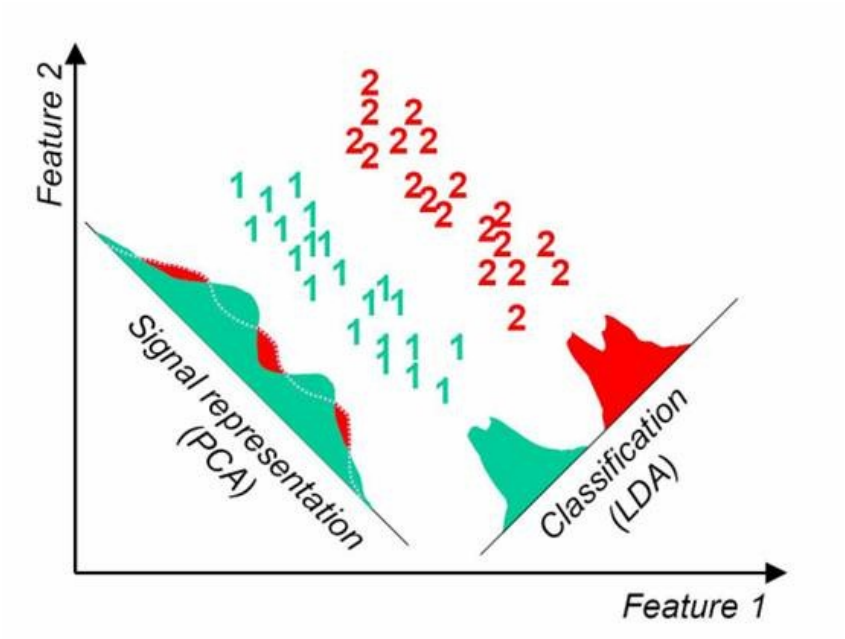


图 2.2: LDA 利用标记信息, 考虑不同组间的相关因素

## 第 4 节　监督学习的优化建模

除了 LDA, 对于一般的监督学习, 我们有额外的标记信息. 利用这些信息, 从优化的角度出发, 我们把最小化的损失函数定义为

$$\min_{\mathbf{W}\in\mathcal{S}_+^d} r(\mathbf{W}) + \lambda \sum_{i=1}^{d} L_i(\mathbf{X}^\top \mathbf{W}\mathbf{X}) \tag{2.1}$$

也可以写成有约束的形式:

$$\begin{aligned} \min_{\mathbf{W}\in\mathcal{S}_+^d} \quad & r(\mathbf{W}) \\ \text{s.t.} \quad & L_i(\mathbf{X}^\top \mathbf{W}\mathbf{X}) < 0 \end{aligned} \tag{2.2}$$

其中 $L_i$ 是损失函数, 也就是区分错误时优化目标函数增加的 “损失”, $r(W)$ 称为正则化项, $\lambda$ 是平衡 (trade-off) 正则化程度的系数. $\mathcal{S}_+^d$ 也可以取为其他的约束, 比如半正定对角阵等 (意为假设每个变量不相关).

### 损失函数

常见的损失函数包括 0-1 Loss, Hinge Loss 函数 (用于下文介绍的软边界 SVM 问题), 指数损失函数,Logistic 损失函数等 (及其变体).

| 损失函数 | 对应方程 | 阶数 | 应用 |
|---|---|---|---|
| 0-1 Loss | $\chi(yf(x)) \le 0$ | 常数 | |
| Exponential Loss | $\exp(-yf(x))$ | 指数 | |
| Logistic | $\log(1+\exp(-yf(x)))$ | 线性 | |
| Hinge loss | $\max(0, 1-yf(x)) := (1-yf(x))_+$ | 线性 | SVM |
| $p$ 阶 Hinge loss | $\max(0, 1-yf(x))^p := (1-yf(x))_+^p$ | $p$ 阶 | |

表 2.1: 常见的损失函数

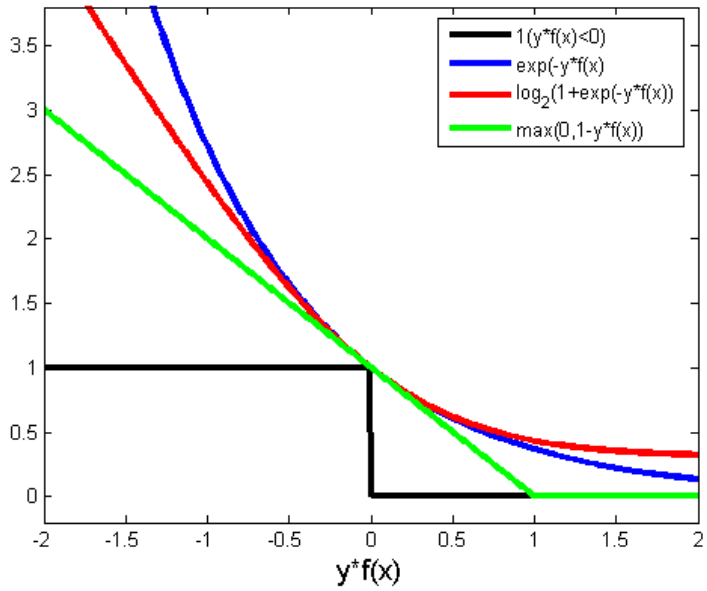


图 2.3: 常见的损失函数

不同的损失函数对错误判别的惩罚程度不一样, 分类错误时损失函数随 $f$ 值的变化的阶数不同. 损失函数有修正和变体, 例如, 注意到判别正确但函数值接近 0 的时候惩罚大于 0, 于是可以将 Hinge Loss 中的常数从 1 修正为 $\alpha \in [0,1]$ 等. 对损失函数的处理这里不展开讨论.

### 正则化项

对于适定性差的问题, 或者说比较杂乱的数据, 为了避免过拟合, 添加正则化项 $r$, 这样做可以视为光滑化. 此外还有早停 (Early-stopping) 等方法, 即不等到计算到最优解即停止优化迭代. 度量学习中常用的正则化包括 Frobenious 范数, 核范数 (迹) 及其推广, 信息理论的正则化 (Information Theoretical Metric Learning, ITML)(具体例子参看第三章2.2节) 等等.

### 优化

优化问题的数值方法有很多, 比如随机梯度下降,Bregman 投影等等, 可以参看 [13][19]. 本文的算法实验中主要采用了随机共轭梯度下降法 (代码由 Carl Rasmussen, 2006 提供).

### 4.1 扩大边缘最近邻 (LMNN) 模型

下面举一个正则化模型的例子.LMNN(Large Margin Nearest Neighbour)[19] 是著名的监督度量学习算法, 有很多基于此的衍生算法. 其想法是使得同一组的距离更近, 不同组的更远. 给定 $k$, $\mathcal{N} = \{(i,j)|j$ 是 $i$ 的 $k$ 近邻 $\}$, 同一类别定义为等价关系为 $\sim$, 相似二元关系 $\mathcal{S} = \{(i,j)|i \neq j, x_i \sim x_j\} \cap \mathcal{N}$, 前两个相似, 且与后一个不相似的三元组 $\mathcal{R} = \{(i,j,k)|x_i \sim x_j \nsim x_k\} \cap \mathcal{N}$, 则优化问题可以定义为

$$\min_{W \in \mathcal{S}_+^d} \sum_{(i,j)\in\mathcal{S}} d_{\mathbf{W}}(x_i, x_j) + \lambda \sum_{(i,j,k)\in\mathcal{R}} (1 + d(x_i, x_j) - d(x_j, x_k))_+$$

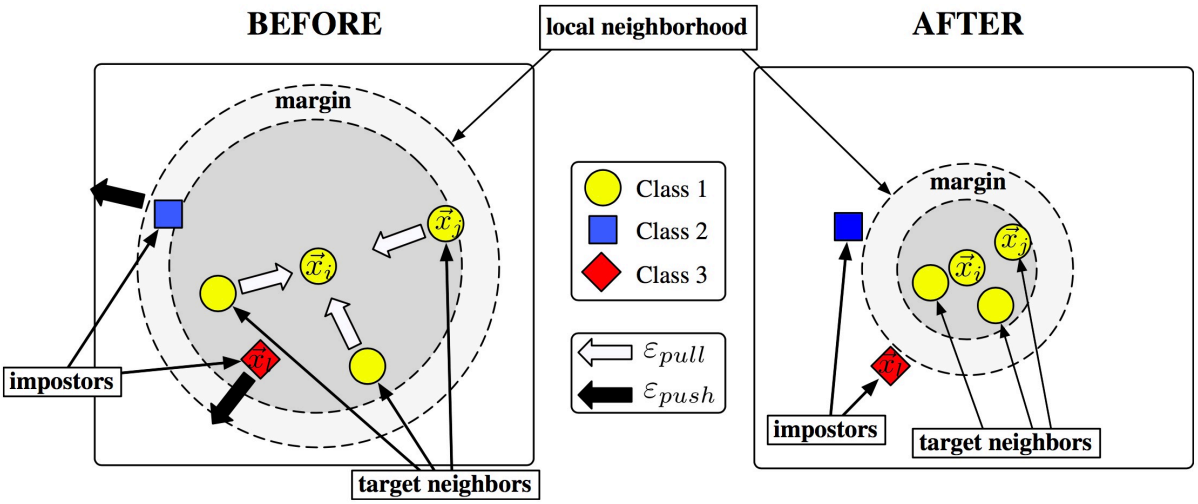


图 2.4: LMNN 的效果图, 图片来自 Weinberger(2009)[19]. 如果某个 Mahalanobis 矩阵将某两个临近的不同组数据算出比某两个同一组距离更小, 那么小过的部分 $\varsigma$ 将受到 “惩罚”(取的是 Hinge Loss, 这个惩罚随 $\varsigma$ 线性递增)

虽然 LMNN 利用局部信息, 但是仍然是一个全局线性度量的算法. 此外还有 POLA, NCA, MCML, ITML 等, 这里不一一列举, 代码将提供于本文的在线材料中.

# 第三章　非线性度量学习

## 第 1 节　问题目标

在实际问题中, 常常会遇到线性无法分割的情形. 例如图3.1, 线性度量并不能将两组区分开来. 为了说明问题的实际意义, 我们同样举一个例子.

**例 3**　两种葡萄和两种橙子, 抽样测得其数据大体如下:

| | 酸度高 | 酸度低 |
|---|---|---|
| 甜度高 | 进口橙子 | 新疆葡萄 |
| 甜度低 | 某品种葡萄 | 某品种橙子 |

表 3.1: 两种橙子的甜度酸度同时很高或同时很低, 而两种葡萄的甜度和酸度一高一低. 仅仅考虑这两个特征, 则线性度量下的监督学习算法不可能得到一个满足条件的距离函数

一般而言, 数据常常出现以下的情况:

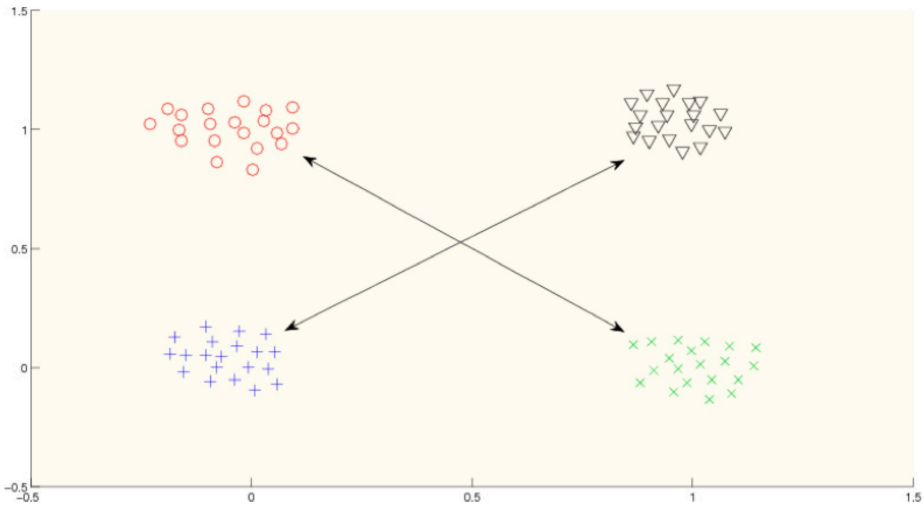


图 3.1: 箭头所指的红绿为一组, 蓝黑为一组, 那么线性距离无法分割这两组 (图片来自 [13])

受到这个例子的启示, 我们将度量公理2.1.的第三条凸性减弱为:

**公理** 3.1. (**局部凸性**) 在局部 (某个合适大小的邻域) 满足 $d(x,y)+d(y,z)\geq d(x,z)$

**注** 3.1 不同的问题所需要的局部范围不一样. 这里的邻域大小可以由核方法的参数体现, 例如下文中高斯核的带宽参数 $\sigma$ 越大, 则视为满足局部凸性的"邻域"越大.

由注2.2的分解定理, 核函数等价于到核空间的变换. 核方法由 Aizerman(1960) 提出, 起初是应用在感知机 (单层神经网络) 中, 90 年代开始应用在支持向量机 (SVM) 中, 在近年的深度学习出现之前, 基于核方法的 SVM 一直是主流.

## 第 2 节　核技巧

上文的 Mercer 定理指出度量学习等价于映射到核空间中的欧氏距离, 支持向量机便是在核空间中用线性分类器, 是度量学习的一种特殊应用. 为了助于理解核方法的动机, 以及核化度量学习的应用, 下面我们回顾它在支持向量机中的应用.

### 2.1　核化支持向量机 (SVM)

软边界的支持向量机问题定义如下:

$$\min_{\zeta_i} \quad \frac{1}{n}\sum_{i=1}^{n}\zeta_i+\lambda\|w\|^2 \tag{3.1}$$

$$\text{s.t.} \quad y_i(w\cdot x_i+b)\geq 1-\zeta_i,\forall i \tag{3.2}$$

$$\zeta_i\geq 0$$

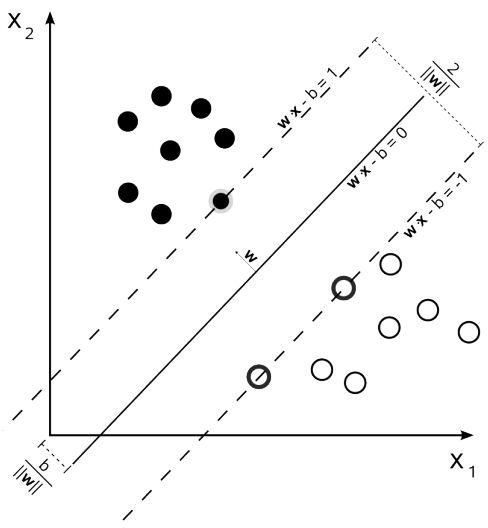


图 3.2: 支持向量机优化超平面的位置, 使得在这个平面两边数据的距离 (尽可能少例外地) 最大, 图片来自维基百科.

写成约束形式后, 解这个问题的对偶问题 (参看 [2]), 得到

$$\begin{aligned} \min_{w} \quad & f(c_1 \dots c_n) = \sum_{i=1}^{n} c_i - \frac{1}{2} \sum_{i=1}^{n} \sum_{j=1}^{n} y_i c_i (x_i \cdot x_j) y_j c_j, \\ \text{s.t.} \quad & \sum_{i=1}^{n} c_i y_i = 0,\ 0 \le c_i \le \frac{1}{2n\lambda}\ \forall i. \end{aligned} \tag{3.3}$$

将这里的 $x_i \cdot x_j$ 替换为 $k(x_i, x_j)$ 即为核技巧.

核技巧的想法是把优化问题中出现的数据之间的内积 $x_i \cdot x_j$(对应满足*凸性*的距离函数), 一般化为**核函数** (这导致了*局部凸*的距离函数), 高斯核 (3.6) 就是一个很好的例子, 它的支集在零点周围, 使得度量函数仅仅在 $x_i, x_j$ 很近的时候取足够大的值, 影响惩罚函数, 使得度量仅仅在局部函数满足凸性.

常用的核函数有:

$$\text{线性核:} k_{LIN}(\mathbf{x}_i, \mathbf{x}_j) = \langle \mathbf{x}_i, \mathbf{x}_j \rangle, \text{对应普通的软边界 SVM 问题} \tag{3.4}$$

$$\text{多项式核:} k_{POL}(\mathbf{x}_i, \mathbf{x}_j) = (\langle \mathbf{x}_i, \mathbf{x}_j \rangle + 1)^q, q \in \mathbb{N} \tag{3.5}$$

$$\text{高斯核:} k_{GAU}(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\|\mathbf{x}_i - \mathbf{x}_j\|_2^2 / \sigma^2), \sigma \in \mathbb{R}_+. \tag{3.6}$$

特别地, 高斯核是*基于两点间距离的核函数 Radial Basis Function(RBF)*. 核函数法的应用包括*感知器 (Perceptron)*, 或称作单层神经网络, 支持向量机 (SVM), 岭回归,PCA(包括谱聚类) 等. 算法的好坏直接依赖于核函数的选取, 例如应用于 SVM 时, 在自然语言处理 (Lodhi et al., 2002) 和生物信息学 (Schölkopf et al., 2004) 中有具体设计的核函数. 核函数选择可以参看文献 [8]. 鉴于 SVM 模型的效果很大程度上依赖于核函数, 下文会探讨*多核学习*对核方法的推广.

### 2.2 正则化项的谱理论

正则化项控制的是核函数 $k$ 的某个形式的范数. 在同构意义下, 定义为对应双线性型的范数 $\|k\| := \|T_k\| = \sup_{\|e_i\|=1} \langle T_k e_i(x), e_i(x) \rangle$. 这个范数由 Mercer 定理 (注2.1) 可以表示如下.

**推论** 3.2. (迹) *设核函数 $k$ 满足 Mercer 条件*,,

$$\langle T_k e_i(x), e_i(x) \rangle = \int_a^b k(x,x) e_i^2(x)\, \mathrm{d}x = \int_a^b k(x,x)\, \mathrm{d}x = \sum_i \lambda_i = \mathrm{tr}(T_k),$$

$$\therefore \|k\| = \sum_i \lambda_i$$

正则化项可以 $r(\mathbf{A})$ 的 2 范数/p 范数/谱范数/迹 (核) 范数/Frobenious 范数但都可以写作 $\mathbf{A}$ 的函数的范数. 一般地, 正则化项 $r$ 为一个*迹类算子*. 作为 $C^*$ 代数上的连

续泛函, 可以进行算子演算 (用 Gelfand 表示定理证明, 参见 [24]), 在度量学习的文献中称之为谱函数, 由谱映射定理容易看出它其实就是某个 $f$ 作用后算子 $k$ 的范数.

**定义** 3.3. (**谱函数**)　*$r$ 称为谱函数, 当且仅当其可以写作*

$$r(\mathbf{A}) = \sum_{\lambda_i \in \sigma_P(\mathbf{A})} f(\lambda_i),$$

*其中 $\lambda_i$ 是 $\mathbf{A}$ 的非零特征值.*

显然, 若 $f$ 是凸的, 则 $r$ 是凸的, 全局最小值容易通过优化解出. 下面列举一些常用的正则化项的谱函数表示:

| 正则化项 | 对应方程 | 谱函数形式 | 举例 |
|---|---|---|---|
| 迹/核范数 (trace) | $\mathrm{tr}(\mathbf{A})$ | $f(\lambda_i) = \lambda_i$ | |
| 推广的迹/核范数 | $\mathrm{tr}(\mathbf{AC})$ | $r(\mathbf{A}) = \sum \boldsymbol{v}^\top \mathbf{C} \boldsymbol{v} \lambda_i$* | LMNN, Xing(2002)[20] |
| 秩 (rank) | $\mathrm{rank}(\mathbf{A})$ | $f(\lambda_i) = 1$ | |
| Frobenious 范数 | $\lVert\mathbf{A}\rVert_F = \sqrt{\mathrm{tr}(\mathbf{A}^\top\mathbf{A})}$ | $f(\lambda_i) = \lambda_i^2$ | Schultz (2003)[17] |
| 信息量 | $\mathrm{tr}(\mathbf{A}) - \log\det(\mathbf{A})$ | $f(\lambda_i) = \lambda_i - \log\lambda_i$ | ITML (Davis et al.) |
| | $\mathrm{tr}(\mathbf{A}\log\mathbf{A} - \mathbf{A})$ | $f(\lambda_i) = \lambda_i \log\lambda_i - \lambda_i$ | |

表 3.2: 常见的正则化项和算法举例

**注** 3.2 (*)　*这里的 $r$ 不是谱函数形式.*$\mathbf{C} = \sum_{(i,j)\in\mathcal{S}}(x_i - x_j)\top(x_i - x_j)$

但是讨论到目前为止, 线性 Mahalanobis 度量学习问题 (2.1) 还不能够应用核函数法. 从两种角度考虑这个问题:(1) 将优化模型表示为关于数据间内积 $\langle x_i, x_j\rangle$ 的问题, 然后将其替换为核矩阵.(2) 将可能为无穷维的核空间表示为低维. 这是下两节的任务.

## 2.3　度量学习的表示定理

对于第 (1) 种方法, 在支持向量机问题中, 我们通过求对偶问题 (3.1) 解决; 在度量学习中, 我们需要引入下面的定理, 说明问题 (2.1) 等价于下面的问题. 证明参看 [12].

**定理** 3.4. (**度量学习的表示定理** [12])　*设 $\mathbf{K} = \mathbf{X}^\top\mathbf{X}$, 定义核空间中的问题*

$$\min_{\mathbf{K_W}\in\mathcal{S}_+^d} r(\mathbf{K}^{-1/2}\mathbf{K_W}\mathbf{K}^{-1/2}) + \lambda\sum_{i=1}^{d} L_i(\mathbf{K_W}) \tag{3.7}$$

*设方程 (2.1) 的最优解为 $\mathbf{W}$, (3.7) 的最优解为 $\mathbf{K_W}$, $\alpha$ 是谱函数中的单项 $f(\lambda_i)$ 的全局最小值,*

*则 $\mathbf{W}$ 可以表示为*

$$\mathbf{W} = \alpha\mathbf{I} + \mathbf{XAX}^\top,$$

其中 $\mathbf{A} = \mathbf{K}^{-1}(\mathbf{K_W} - \alpha\mathbf{K})\mathbf{K}^{-1}$. 且成立:

$$\mathbf{K_W} = \mathbf{X}^\top \mathbf{W}\mathbf{X}.$$

这个定理让核化的度量学习成为可能. 因为核空间往往是无穷维的 (例如高斯核), 用特征映射 $\Phi$ 映射到核空间中, 学习核空间的线性度量矩阵是不现实的. 所以和式核化 SVM 的想法一样, 需要将问题转化为含有数据间内积的形式 ($n$ 阶方阵 $\mathbf{X}^\top\mathbf{X}$). 然后将内积替换为核函数的值 $\mathbf{K}$.

由表2.2看到除了秩范数和信息正则化, 正则化函数的谱函数单项的最小值 $\alpha = 0$, 可以简化运算. 固定特定核函数形式, 仅仅调整参数的模型, 这样往往表示能力不足, 由于这个原因, 下文会把这些核函数进行推广, 加入额外的参数 (不同核函数求和的权重), 增加核函数的表示能力, 这个想法称为*多核学习*.

### 2.4　基于核化主成分分析 (KernelPCA) 的核方法

针对上一节的方法, 虽然把问题化为几乎同样的 SDP 问题 (只是目标矩阵的规模从 $d^2$ 变成了 $n^2$), 但是往往要求重新定义优化问题, 并修改算法 (3.7) 的优化函数, 事实上可以这样考虑: 设数据量为 $n$, 那么这些数据映射到核空间中, 张成的子空间维数至多为 $n$. 以这些数据为基底表示核空间里的子空间就可以把问题化为有限维 (至多 $n$). 这样可以在同构 $I$ 的意义下视为到 $n$ 维欧氏空间的 Kernel PCA 核映射,

$$\Phi_k = \mathbf{I} \circ \Phi : \quad \mathbb{R}^d \longrightarrow \mathbb{R}^d$$

具体的方法是

$$K' = K - \mathbf{1_N}K - K\mathbf{1_N} + \mathbf{1_N}K\mathbf{1_N}$$

, 就可以直接应用度量学习的算法.

可以证明这两种方法事实上是等价的 [13],.

## 第 3 节　多核学习

多核学习的想法是把不同的常用核函数组合起来.

$$k = \sum_{i=1}^{m} \mu_i k_i(x_i, x_j)$$

Gönen(2011)[9] 用交叉验证的方法证实了一般核函数的非线性组合效果更佳, 但是高斯核的*线性*组合更合理. 所以在下一节的测试中, 对高斯核进行线性处理验证. [9] 还测试了各种形式的组合的情况, 但这里只采用基于距离的 (RBF) 高斯核.

### 3.1　多核学习在 LMNN 中的应用

以 LMNN 为例测试了多核方法. 设 KernelPCA 方法的核映射记作 $\Phi_{mk}$, 多核设定下优化问题写作.

$$\begin{aligned} \min_{\mathbf{W}\in\mathcal{S}_+^d} \quad & r(\Phi_{mk}(X)^\top \mathbf{W}\Phi_{mk}(X)) \\ \text{s.t.} \quad & L_i(\ _{mk}(X)^\top \mathbf{W}\ _{mk}(X)) < 0 \end{aligned} \tag{3.8}$$

同 Wang(2011)[18] 的方法一样, 不难看出这个问题可以写成矩阵形式—只要将 $\Phi_{mk}(X)$ 替换为 $\{\Phi_{k_i}\}_{i=1}^m$ 按列排列的分块阵,W 替换为 $(\mu\mu^\top)\otimes W$. 可以把这个矩阵提升为一般的 $\tilde{W}$(非正则的 LMNN), 由于自由度变大 (从 $d\times n^2$ 变成 $(nd)^2$), 需要足够的数据以避免欠拟合.

## 第 4 节　算法实验

SVM 问题的复杂度一般为*二次规划 (QP) 问题*, 度量学习一般为*半正定规划 (SDP) 问题* [9]. 采取随机共轭梯度下降法, 本文提到的算法结果如下:

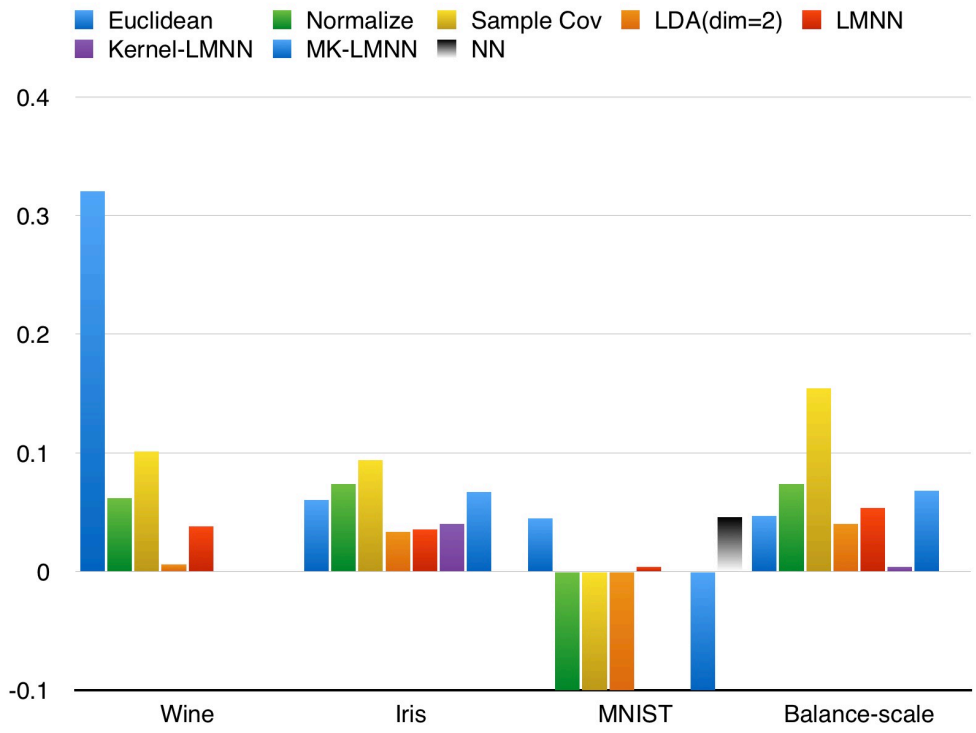


图 3.3: 各数据集二折验证的错误率

| ↓方法 \| 数据集→ | Wine | Iris | MNIST | Balance-scale | 备注 |
|---|---|---|---|---|---|
| **条目 n** | 178 | 149 | 1000 | 149 | |
| **特征数 d** | 13 | 4 | 784 | 4 | 数据属性 |
| **类别数 classes** | 3 | 3 | 10 | 3 | |
| **Euclidean** | 0.3202 | 0.0604 | 0.0450 | 0.0470 | 算法基准值 |
| **Normalize** | 0.0618 | 0.0738 | -0.1 | 0.0738 | 算法不适用则设为-0.1 |
| **Sample Cov** | 0.1011 | 0.0940 | -0.1 | 0.1544 | 同上 |
| **LDA(dim=2)** | 0.0060 | **0.0336** | -0.1 | 0.0403 | MNIST: 训练样本不足 |
| **LMNN** | 0.0379 | 0.0356 | 0.0040 | 0.0537 | |
| **Kernel-LMNN** | **0** | 0.0403 | **0** | **0.0040** | |
| **MK-LMNN** | **0** | 0.0671 | -0.1 | 0.0678 | MNIST: 维数太高 |
| **NN** | | | 0.0458 | | n=5949, dim=30 |

选取了四个数据集, 核方法的 LMNN 根据交叉验证, 采用了 $\sigma = 10$, 对 Wine 和 Balance-scale 数据非常有效, 特别是 Wine 数据达到了 100% 识别, 但是对 Iris 表现不佳, 非正则化多核方法普遍识别率比较低, 因为冗余参数过多, 存在严重的欠拟合. 和 Gai(2010)[8] 相同, 选用多项式核 (次数从 1 到 10) 和高斯核. 取带宽

$$\sigma \in \{0.5, 1, 2, 5, 7, 10, 12, 15, 17, 20\}.$$

虽然从模型选择, 或者说逼近论的角度而言, 无论是高斯核还是多项式核的线性组合都不能表示所有关于距离递减的函数的空间, 例如高斯函数满足 $f(x;\sigma) = \frac{1}{\sigma} f(\frac{x}{\sigma}; 1)$, 全体高斯函数张成的空间远远不能表示所有的核函数, 但选择这些函数足以测试多核学习算法的有效性 [16].

特别地, 对高维数据的神经网络法进行了调整测试, 对 500-500-2000-30 网络, 运行 30 轮向后传播算法,5949 训练集测试,1000 数据集, 运行 3 小时 (Intel I5 core 2.7 GHz) 的结果为 4.58% 误差,Science 的论文中 60 轮的结果为 1% 左右. 低维的数据并不足以训练如此庞大的网络.

# 第四章　延伸讨论

虽然核方法实现了用度量学习非线性的问题, 但是这个度量本质上还是核空间上全局线性的. 除此之外还有一些局部/非线性的方法. 这也是这篇论文的初衷之一. 局部自适应度量学习 (Local Adaptive Distance Metric Learning) 可以参看文献 [10] [5] [15] [23] [6] [22].

## 第 1 节　核函数法之外的非线性度量学习

### 1.1　非 Mahalanobis 方法

Frome (2007)[7] 在每一个点学习一个度量. 定义基本距离函数 $d_{ij}$, 表示特征 $i$ 和 $j$ 之间的距离, 这样推广了线性结构的度量 (上文的 Mahalanobis 矩阵), 在每一个点都有一个距离函数. $\boldsymbol{w}_i$ 为 $i$ 点的权重向量. $d(x_i, x_j)\boldsymbol{w}_i^\top \boldsymbol{d}_{ij}$ 表示在 $i$ 点的局部距离函数. $\mathbf{W} = [\boldsymbol{w}_1, \cdots, \boldsymbol{w}_n]$ 是学习目标,

由此定义优化问题:

$$\min_{\mathbf{K}_\mathbf{W} \in \mathcal{S}_+^d} \frac{1}{2}\|\mathbf{W}\|_F + \lambda \sum_{(i,j,k) in \mathcal{R}} (1 + \boldsymbol{w}_i^\top \boldsymbol{d}_{ij} - \boldsymbol{w}_i^\top \boldsymbol{d}_{ik})_+ \tag{4.1}$$

和多核学习类似, 这个问题可以化归为原问题的表示方式, 设 $n^2$ 个数据点

$$x_{ip} = (\mathbf{0} \quad \boldsymbol{x} \quad \mathbf{0}),$$
$$\uparrow \text{第 p 个位置}$$

学习目标矩阵

$$\begin{aligned}\mathbf{W} &= \mathrm{diag}(\boldsymbol{w}_1 \cdots \boldsymbol{w}_n) \\ &= \begin{pmatrix} \mathrm{diag}(\boldsymbol{w}_1) & & \\ & \ddots & \\ & & \mathrm{diag}(\boldsymbol{w}_n) \end{pmatrix}.\end{aligned}$$

则 p 点的局部度量 $d_p(x_i, x_j) = x_{ip}\mathbf{W}x_{jp}$. 这样问题化归为线性 Mahalanobis 矩阵, 已经用 LMNN 等算法解决, 而且和上文一样可以用核函数法处理. 坏处是学习的度量矩阵变成了 $n^2$ 阶方阵, 计算量非常大.

### 1.2 概率方法

回顾第二章第2节的定义, 仅仅在 $\mathbb{R}^d$ 中考虑. 这样的聚类结果仅仅包含了空间上的特定两点的距离, 现在我们赋予空间概率结构: 考虑概率空间 $(\mathbb{R}^d, \Omega, \mathbb{P})$. 应用到有监督的 *k-NN* 聚类中, 从概率的角度出发, 可以这样解释: 假设数据的真实分布未知, 局部为某个分类的概率相同, 则

$$\mathbb{P}(x) = \frac{\sum_i \chi_{(x_i,x)\in\mathcal{S}\cap\mathcal{N}}}{\sum_i \chi_{(x_i,x\in\mathcal{N}}}$$

式中 $\mathcal{N}$ 为 k 近邻的集合.

又例如 Bohné, Ying et. al. (2017) 引入了一个局部度量方法, 上的问题, 先假设数据服从混合高斯模型 (GMM), 用期望最大化 (EM) 方法算出概率, 在此基础上逐步改进 GMM 的参数, 同时学习度量函数 [1].

### 1.3 卷积神经网络 (CNN) 方法

受注2.1和注2.2启发, 可以把核方法和 Mahalanobis 距离结合起来:

$$d_{\mathbf{W}}(\Phi(x_1), \Phi(x_2)) = \|\mathbf{L}\Phi(x_1) - \mathbf{L}\Phi(x_2)\|_2^2 := \|\Psi(x_1) - \Psi(x_2)\|_2^2$$

于是可以用欧氏度量进行线性分类. 与一般的核方法映射到可能无穷维的核空间, 再用内积替换间接求解不同的是, 这里的映射 $\Psi$ 的目的是把数据映到低维的 "核空间" 直接分类. 例如 Chopra (2005) [3], Hinton(2006) [11] 等. 在前面的算法实现部分进行了测试.

### 1.4 流形学习

回忆第二章开头的相似度学习是寻找相似性函数, 机器学习的另一个视角, 是*表示学习*, 即求数据的有效表示. 在非监督的问题中, 没有标注的信息, 例如**流形学习**, 又称非线性降维, 是假设高维数据的表示往往具有低维的结构 (此外还有稀疏编码 (假设数据为简单元素的组合), 多线性子空间学习 (线性方法如 PCA 在多线性情形的推广)). 流形学习, 顾名思义, 就是将流形 $\mathcal{M}^p \subseteq \mathbb{R}^d$ *共形映射*为 $\mathbb{R}^p$ 空间, 按照地球仪画成世界地图的方式将流形 "剥" 下来. 基于这个想法, 我们添加一条公理, 描述局部低维结构:

**公理** 4.1. (**流形**)　*在局部 (某个合适大小的邻域) 满足同胚于* $\mathbb{R}^p, p < d$

方法有很多, 可以参看局部线性嵌入 (LLE), 多维标度 (MDS)[4],ISOMAP 等等 [21]. 在低维空间上可以进一步进行度量学习等方法, 很多方法都和度量学习有关.

# 第五章　小结

度量学习的目标是给定数据, 求空间中的度量函数使得基于度量的算法效果最佳. 假设度量空间具有凸性和线性性, 度量由正定矩阵给出, 由对称正定 Mahalanobis 决定. 这样的度量空间结构相当于做了一个线性变换后, 化归了为欧氏度量结构. 假设非线性, 将条件减弱为局部凸, 可以引入核方法 (Kernel Method) 处理, 同样可以等价于一个非线性变换下的欧氏度量.

可以看成两种目标: 非线性升维 (核空间), 和非线性降维 (流形学习). 这两种截然相反的思路最终殊途同归, 都是希望寻找一个能够化为简单问题的某个空间. 二者之间可以互相借鉴, 可以组合出很多种方法:LDA 等方法视为降维, 核方法视为升维. 实际问题中可以通过预判断和先验知识选择合适的算法, 例如可以通过 LDA 发现 wine 数据具有良好的高斯性质;MNIST 这样高维数据由于空间复杂度不适合多核方法, 低数目的数据不适合表示力过强的模型, 比如很多核函数组成的多核学习, 神经网络等等. 正如*没有免费午餐定理 (NFL Theorem)* 指出的一样, 模型有不同的适应性, 没有绝对的好坏之分.

无论是核方法还是神经网络, 算法的准确度依赖于参数的表示能力 (参数数目), 以及能否拟合得好 (训练样本), 随之而来的是算法和计算量的爆炸式增长. 神经网络表示能力过强, 需要人为简化结构与扩大训练数据样本量, 多核方法同样存在这个问题, 这个是下一步要讨论和实践的问题. 此外, 本文仅仅讨论了分类问题, 对于排名和回归, 有待于进一步整理.

是否有标记数据信息, 可以将算法分为监督: RCA NCA LMNN LDA, 和非监督 (仅仅假设低维结构): PCA MDS LLE LPP 等. 论文中没有介绍的方法在补充材料中提供. 本论文的成果除了度量学习的框架和案例分析, 还包括整理的工具包, 将在http://changqingfu.com/不定期更新.

# 致谢

感谢论文导师石磊老师对我的教导和帮助.

感谢张静老师, 赵冬华老师, 姚一隽老师对我留学申请作出的帮助与建议, 以及杨翎老师, 希伯来大学的 Alon Eizenberg 老师, 中北大学的张天德老师, 剑桥大学的 Alan Barrell 老师, 北京大学的姚远老师对我的鼓励, 帮助与指点.

感谢父母的养育和照顾, 女朋友的体贴和关心, 三位室友的陪伴和互助, 以及大学一起共事过的各位朋友的情义.

感谢任课教师傅吉祥老师, 吴新明老师, 林伟老师, 陈纪修老师, 王志强老师, 吴昊老师, 吕志老师, 郭坤宇老师, 姜文华老师, Eberhard Guhe 老师, 谢启鸿老师, 黄昭波老师, 高卫国老师, 张淑琴老师, 严军老师, 谢践生老师, 李洪全老师, 陈猛老师, 严金海老师等等的教诲.

# 参考文献


[1] Julien Bohné, Yiming Ying, Stéphane Gentric, and Massimiliano Pontil. Learning local metrics from pairwise similarity data. *Pattern Recognition*, 2017.

[2] Stephen Boyd and Lieven Vandenberghe. *Convex optimization*. Cambridge university press, 2004.

[3] Sumit Chopra, Raia Hadsell, and Yann LeCun. Learning a similarity metric discriminatively, with application to face verification. In *Computer Vision and Pattern Recognition, 2005. CVPR 2005. IEEE Computer Society Conference on*, volume 1, pages 539–546. IEEE, 2005.

[4] Trevor F Cox and Michael AA Cox. *Multidimensional scaling*. CRC press, 2000.

[5] Carlotta Domeniconi, Dimitrios Gunopulos, et al. Adaptive nearest neighbor classification using support vector machines. In *NIPS*, pages 665–672, 2001.

[6] Jerome H Friedman et al. Flexible metric nearest neighbor classification. Technical report, Technical report, Department of Statistics, Stanford University, 1994.

[7] Andrea Frome, Yoram Singer, Fei Sha, and Jitendra Malik. Learning globally-consistent local distance functions for shape-based image retrieval and classification. In *Computer Vision, 2007. ICCV 2007. IEEE 11th International Conference on*, pages 1–8. IEEE, 2007.

[8] Kun Gai, Guangyun Chen, and Chang-shui Zhang. Learning kernels with radiuses of minimum enclosing balls. In *Advances in neural information processing systems*, pages 649–657, 2010.

[9] Mehmet Gönen and Ethem Alpaydın. Multiple kernel learning algorithms. *Journal of Machine Learning Research*, 12(Jul):2211–2268, 2011.

[10] Trevor Hastie and Robert Tibshirani. Discriminant adaptive nearest neighbor classification. *IEEE transactions on pattern analysis and machine intelligence*, 18(6):607–616, 1996.

[11] Geoffrey E Hinton and Ruslan R Salakhutdinov. Reducing the dimensionality of data with neural networks. *science*, 313(5786):504–507, 2006.

[12] Prateek Jain, Brian Kulis, and Inderjit S Dhillon. Inductive regularized learning of kernel functions. In *Advances in neural information processing systems*, pages 946–954, 2010.

[13] Brian Kulis et al. Metric learning: A survey. *Foundations and Trends® in Machine Learning*, 5(4):287–364, 2013.

[14] M. Lichman. UCI machine learning repository, 2013.

[15] Jing Peng, Douglas R Heisterkamp, and HK Dai. Adaptive kernel metric nearest neighbor classification. In *Pattern Recognition, 2002. Proceedings. 16th International Conference on*, volume 3, pages 33–36. IEEE, 2002.

[16] Alain Rakotomamonjy, Francis R Bach, Stéphane Canu, and Yves Grandvalet. Simplemkl. *Journal of Machine Learning Research*, 9(Nov):2491–2521, 2008.

[17] Matthew Schultz and Thorsten Joachims. Learning a distance metric from relative comparisons. In *NIPS*, volume 1, page 2, 2003.

[18] Jun Wang, Huyen T Do, Adam Woznica, and Alexandros Kalousis. Metric learning with multiple kernels. In *Advances in neural information processing systems*, pages 1170–1178, 2011.

[19] K.Q. Weinberger and L.K. Saul. Distance metric learning for large margin nearest neighbor classification. *The Journal of Machine Learning Research*, 10:207–244, 2009.

[20] Eric P Xing, Andrew Y Ng, Michael I Jordan, and Stuart Russell. Distance metric learning with application to clustering with side-information. In *NIPS*, volume 15, page 12, 2002.

[21] Liu Yang and Rong Jin. Distance metric learning: A comprehensive survey. *Michigan State Universiy*, 2(2), 2006.

[22] Kai Zhang, Ming Tang, and James T Kwok. Applying neighborhood consistency for fast clustering and kernel density estimation. In *Computer Vision and Pattern Recognition, 2005. CVPR 2005. IEEE Computer Society Conference on*, volume 2, pages 1001–1007. IEEE, 2005.

[23] Zhihua Zhang, James T Kwok, and Dit-Yan Yeung. Parametric distance metric learning with label information. In *IJCAI*, page 1450. Citeseer, 2003.

[24] 郭坤宇. 算子理论基础. 复旦大学出版社, 2014.